로그라이크 강화학습 프로젝트

결과 보고서

게임 제작 → AI 강화학습 → 전술 추천, 그리고 그 사이의 수많은 시행착오

작성일: 2026-07-15

목차

1. 한눈에 보기 (요약)

이 프로젝트의 목표는 세 가지였다. 첫째, 로그라이크 게임을 직접 만든다. 둘째, 그 게임을 AI에게 강화학습으로 시켜 최종 보스를 처치하는 법을 스스로 익히게 한다. 셋째, 그렇게 배운 전술을 사용자에게 상황에 맞게 추천한다. 결론부터 말하면, 세 기둥 모두 실제로 구현하고 연결하는 데 성공했다. 고정된 지도에서 AI는 300판 중 300판, 즉 100%를 승리했고, 그 학습된 판단을 바탕으로 상황별 전술을 사람에게 조언하는 도구까지 완성했다.

그러나 이 보고서의 진짜 핵심은 '100% 승리'라는 결과가 아니라, 거기에 도달하기까지 겪은 수많은 실패와 그 해결 과정이다. AI는 처음에 무작위보다도 못했고, 12시간짜리 무한 루프 버그에 걸렸으며, 겁을 먹고 벽에 숨었고, 결국 이겼을 때는 '스피드러너'가 되어버렸다. 이 시행착오의 연대기야말로 강화학습의 실제 모습이며, 이 프로젝트가 남긴 가장 값진 배움이다.

결과 요약

항목	결과
게임	격자 로그라이크(이동·전투·아이템·여러 층·보스) 완성. 사람 플레이 가능.
AI 학습	PPO(Stable-Baselines3)로 학습. 고정 맵에서 보스 처치 승률 100% 달성.
전술 추천	현재 상황에서 AI가 추천 행동·확신도·이유를 알려주는 'AI 코치' 완성.
핵심 배움	보상 설계, 정책 붕괴, 커리큘럼 학습, 모델의 한계, ML의 경제학까지 실전 경험.

2. 무엇을 만들었나

프로젝트는 크게 네 덩어리로 이루어진다. 각각을 따로 만들고 서로 연결했다.

구성	역할	핵심 파일
게임 엔진	로그라이크 규칙(맵·이동·전투·아이템·층·보스)	map.py, player.py, player3.py, player4.py
학습 환경	게임을 AI가 다룰 수 있는 Gymnasium 규격으로 래핑	rogue_env.py

구성	역할	핵심 파일
학습·평가	PPO 학습, 성적 측정, 무작위 기준선	train_curriculum, evaluate, baseline
관전·추천	학습 AI 관전, 상황별 전술 추천(AI 코치)	watch.py, recommend.py

게임은 사람이 직접 w/a/s/d로 플레이할 수 있고, 무기·포션을 모으며 몬스터를 처치하고 층을 내려가 보스를 잡으면 승리한다. AI는 이 게임을 숫자로 바꿔서(관측) 받고, 상/하/좌/우 네 가지 행동 중 하나를 골라 플레이한다. 어떤 행동이 좋았는지는 오직 '보상 점수'로만 판단한다.

3. 시행착오 연대기 (이 프로젝트의 핵심)

아래는 AI를 '이기게' 만들기까지 겪은 문제와 해결 과정을 시간순으로 정리한 것이다. 각 단계는 '무엇이 문제였고, 왜 그랬으며, 어떻게 풀었는가'로 되어 있다.

3.1 첫 시도 — 학습이 되지 않았다

처음 만든 보상은 '보스를 잡으면 +10' 같은 드문 보상 위주였다. 무작위로 플레이하면 보스를 잡을 확률이 1%도 안 되니, AI는 그 '성공의 감각'을 거의 경험하지 못했다. 결과적으로 학습을 시켜도 무작위(평균 보상 -9.8)와 다를 바 없이 목표를 못 찾고 배회했다. 교훈: 좋은 결과가 충분히 자주 일어나야 배울 실마리가 생긴다(희소 보상 문제).

3.2 숨어 있던 버그 — 12시간 무한 루프

학습된 AI를 평가하는데 프로그램이 12시간이 지나도 끝나지 않았다. 원인은 환경 코드에서 '벽에 부딪히면 즉시 함수를 빠져나가는' 처리가, 그 아래에 있는 '200걸음이면 판을 끝내라'는 안전장치를 건너뛰게 만든 것이었다. 무작위로 플레이할 땐 벽에서 금방 벗어나 문제가 없었지만, 학습된 AI가 한 방향만 고집해 벽에 영원히 박히자 판이 끝나지 않았다. 안전장치를 벽 처리 안으로 옮겨 해결했다. 교훈: 무작위 테스트에선 멀쩡했다가 실제 정책에서 터지는 버그가 있다.

3.3 정책 붕괴 — 무작위보다 못한 AI

보상이 척박하면 AI는 시도조차 포기하고 아무 의미 없는 한 가지 행동으로 굳어버린다(정책 붕괴). 이때 학습된 AI는 '벽 근처에서 시간만 때우는 겁쟁이'가 되어, 평가 점수가 무작위(-9.8)보다도 나쁜 -28을 기록했다. 벽에 부딪히는 행동은 위험을 회피하는 '안전한 은신처'였기 때문이다. 학습 중 점수(탐험이 섞여 부풀려진 값)와 실제 실력(확신하는 행동만 골랐을 때)이 크게 다르다는 것도 이때 확인했다.

3.4 보상 재설계 + 랜덤 인카운터

사용자의 문제의식('몬스터를 피해 아이템만 주울 수 있으니 전투를 강제해야 한다')을 반영해, 필드를 걸을 때 확률적으로 전투가 벌어지는 '랜덤 인카운터'를 넣고, 각 층 첫 처치 보너스 등 보상을 다듬었다. 그 결과 무작위 기준선의 평균 보상이 -9.8에서 +1.95로 올라, 처음으로 'AI가 기어오를 언덕(양수 보상)'이 생겼다. 다만 학습된 AI는 이번엔 위험한 필드를 피해 벽에 숨는 쪽으로 다시 굳어버렸다(난이도 과보정).

3.5 커리큘럼 학습 — 걷기부터 배우고 뛰게 하기

처음부터 위험한 환경에 던지지 않고, 위험이 없는 안전한 세상에서 기본기를 익히게 한 뒤 난이도(인카운터 확률)를 단계적으로 올리는 커리큘럼을 적용했다. 안전한 1단계에서 학습 곡선이 깔끔하게 상승해 '기초는 잡혔다'를 확인했다. 하지만 마지막 전체 난이도 단계에서 다시 불안정해졌고, 평가 성적도 여전히 무작위 미만이었다.

3.6 진짜 병목과 '우연한 성공의 빈도'

여러 시도 끝에 진짜 병목을 찾았다. 매 판 지도가 무작위로 바뀌기 때문에, 단순한 신경망(MLP)이 '처음 보는 지도에서 길 찾기'라는 일반화를 해내기가 벅찼던 것이다. 여기서 강화학습의 핵심 원리를 실험으로 확인했다: AI는 게임을 이해하는 게 아니라, '우연한 성공'이 충분히 자주 일어나야 그 감각을 학습한다. 실제로 층과 보스를 쉽게 낮추자 무작위조차 보스를 잡는 확률이 0.7%에서 10~16%로 20배 넘게 뛰었다.

3.7 맵 고정 — 드디어 100% 승리 (그리고 스피드러너)

추천 기능을 만들려면 '이기는 정책'이 먼저 있어야 했다. 그래서 매 판 지도를 고정해 일반화 부담을 없앴다. 그러자 단순한 AI도 그 지도의 승리 경로를 완벽히 익혀 300판 전부(100%)를 평균 21걸음 만에 클리어했다. 다만 예상대로 '스피드러너'가 되었다 — 무기만 최소한 챙기고 보스로 직행하는 최단 경로를 학습한 것이다. 이는 버그가 아니라 보상(빠른 승리에 유리)의 정확한 결과였고, 'AI는 시킨 것만 최적화한다'는 교훈의 완벽한 실례다.

4. 단계별 성적 변화

같은 방식(300판, 결정론적)으로 측정한 학습 AI의 성적 변화다. 숫자가 아니라 '방향'을 보라 — 실패에서 성공으로 어떻게 이동했는지.

단계	평균 보상	클리어율	시간초과
무작위 기준선(초기)	-9.8	1.0%	95.7%
1차 학습(희소 보상)	-28.1	0.0%	99.7%
보상 재설계 v2	-21.4	0.0%	95.3%
커리큘럼	-19.0	0.0%	91.3%

단계	평균 보상	클리어율	시간초과
난이도 하향(층2·보스5)	-17.8	1.7%	86.3%
맵 고정 (최종)	+20.6	100.0%	0.0%

표에서 보이듯, 여러 번의 실패는 조금씩이지만 분명히 개선의 방향으로 나아갔고, 마지막 '맵 고정' 한 수로 완전한 승리에 도달했다.

5. 핵심 교훈

- AI는 시킨 것(보상)만 최적화한다. '재미'나 '사람이 보기에 합리적인가'가 아니라 오직 보상 점수를 높이는 쪽으로만 움직인다. 그래서 보상 설계가 곧 행동 설계다.
- 우연한 성공이 학습의 씨앗이다. 좋은 결과가 충분히 자주 일어나야 AI가 그 패턴을 붙잡고 배운다. 과제를 쉽게 만든다는 건 '우연한 성공의 빈도를 높인다'는 뜻이다.
- 학습 점수와 실제 실력은 다르다. 학습 중 점수는 탐험(무작위 시도)의 운이 섞여 부풀려질 수 있다. 진짜 실력은 확신하는 행동만 골라 평가해봐야 안다.
- 모델의 크기·구조·입력이 모두 중요하다. 우리가 쓴 건 아주 작은 신경망이었고, 2차원 지도를 한 줄로 펴서 줘 공간 정보가 뭉개졌다. 지도 같은 데이터엔 CNN처럼 구조를 이해하는 모델이 더 맞다.
- 어려우면 쉬운 것부터(커리큘럼). 처음부터 어려운 과제에 던지면 실패하거나 회피를 배운다. 쉬운 환경에서 기초를 다진 뒤 난이도를 올리는 게 정석이다.
- ML에는 경제학이 있다. 큰 학습은 시간·비용이 크고, 한 번에 근사치라도 못 얻으면 큰 손해다. 그래서 '작게 먼저 검증'(기준선 측정, 소규모 실험)으로 리스크를 줄이는 것이 실무의 핵심 습관이다.

6. 남은 과제와 다음 단계

- 랜덤 맵 재도전: 대규모 학습(수백만~천만 판)이나, 지도를 이미지처럼 이해하는 CNN 정책으로 '매번 다른 지도'까지 정복해보기.
- 전술 추천 개인화: '공격형 / 안전형' 등 사용자 성향에 맞춰 추천의 무게를 바꾸기(설계 문서의 중급 단계).
- 난이도 확장: 고정 맵에서 시작해, 확실히 이기는 것을 확인하며 층·적·무작위성을 조금씩 되살려 일반화 능력을 키우기.

7. 맺음말

이 프로젝트는 '완벽한 보스 학살자'를 만드는 데는 이르지 못했지만, 그보다 훨씬 값진 것을 남겼다. 강화학습이 실제로 어떻게 실패하고 어떻게 고쳐지는지를 직접 겪었다는 점이다. 희소 보상, 정책 붕괴, 겁쟁이 AI, 커리큘럼, 스피드러너 — 이 모든 실패는 교과서로는 와닿지 않는 실전 감각으로 남았다.

그리고 마침내 게임 제작, AI 학습, 전술 추천이라는 세 기둥을 모두 실물로 세웠다. 이것이 이 프로젝트의 성과다.